

CETEC UBATIC 2026-27

Grupo 2: Qdrant + CLIP/CONCH + LangGraph/ADK

Informe Técnico - Etapa 2

Baseline, LLM como Juez y Optimización del Prompt con DSPy GEPA

Mateo Gonzalez Pautaso - Alen Calandria

Octubre 2026

1. Contexto y Objetivo de la Etapa 2

Al cierre de la Etapa 1, el asistente quedó integrado como un agente LangGraph sobre Qdrant, con búsqueda híbrida (vectorial, por entidades y por palabras clave), embeddings de texto MiniLM y embeddings de imagen UNI y PLIP. El sistema medía la recuperación, pero no tenía una forma reproducible de medir la calidad de las respuestas que genera.

Los objetivos de la Etapa 2 fueron:

- Tarea 1: Construir un baseline reproducible que corra el pipeline completo sobre el golden set de 32 preguntas y mida el recall fuente+página@5.
- Tarea 2: Implementar un LLM como juez, con una rúbrica docente de cuatro dimensiones, para puntuar las respuestas y no solo los fragmentos recuperados.
- Tarea 3: Optimizar la instrucción de respuesta con DSPy GEPA, usando el juez como métrica.

Además, hubo que migrar los modelos del pipeline, porque Groq retiró del plan gratuito los dos modelos que usaba el sistema.

2. Cambios de Infraestructura

2.1 Migración de Modelos

Groq retiró Llama-4-Scout el 17/07/2026 y Llama 3.3 70B el 16/08/2026. Desde esas fechas, las llamadas devolvían el error 404 model_not_found. Los reemplazos se eligieron entre los modelos que el plan gratuito sigue ofreciendo:

Rol	Antes	Ahora
Generador (texto e imagen)	Llama-4-Scout	qwen/qwen3.8-27b (multimodal)
Juez	Llama 3.3 70B	openai/gpt-oss-120b
Reflexión de GEPA	(no existía)	openai/gpt-oss-120b

Qwen razona antes de responder, lo que gasta cuota sin aportar a las respuestas del RAG. Por eso se envía con `reasoning_effort=none` y `reasoning_format=hidden`, y se elimina cualquier bloque `<think>` que quede en la respuesta. El modelo se configura con la variable `LLM_MODEL0`.

El script `optimizacion/modelos.py` lista los modelos que ve cada key y, con `--probar`, hace una llamada de texto, una con imagen, una al juez y una al modelo de reflexión. Sirve para detectar un modelo retirado antes de correr una evaluación larga.

2.2 Rotación de API Keys y Límites del Plan Gratuito

La clase RotadorClaves (src/claves.py) reparte las llamadas entre las keys de GROQ_API_KEYS por turnos. Cuando una key recibe un límite de uso (429), queda en pausa el tiempo que indica Groq ("Please try again in 7.5s") y la llamada sigue con la siguiente. Si todas están en pausa y la primera se libera en menos de 90 segundos (GROQ_ESPERA_MAX_S), espera en lugar de fallar.

Groq cuenta los límites por organización, no por key: dos keys de la misma cuenta comparten la cuota. Para que la rotación sirva, las keys tienen que ser de cuentas distintas. Los límites que más afectaron el trabajo fueron:

Límite	Valor	Efecto en el proyecto
Tokens por día, por modelo y cuenta	200.000	Una corrida de GEPA con --budget light agotó al juez en 3 horas con una sola cuenta
Tokens de entrada por minuto de Qwen	7.000	El pedido de extracción del temario (7.760 tokens) se rechazaba con 413; la muestra se redujo a 12.000 caracteres
Tokens de salida por minuto de Qwen	1.000	Groq rechaza pedidos con max_tokens mayor; GEPA usa 900

Un 413 ("Request too large") ya no pausa la key: el pedido excede el límite de cualquier key, así que rotar solo dejaría todas en pausa.

2.3 Renderizado de PDF sin Poppler

El renderizado de páginas pasó a usar PyMuPDF (get_pixmap), con pdf2image como respaldo. En Windows ya no hace falta instalar Poppler ni Tesseract para indexar los manuales.

3. Tarea 1: Baseline sobre el Golden Set

3.1 Golden Set y Métrica

El golden set creció de 30 preguntas en el Sprint 2 a 32: 20 sobre arch2, 5 sobre arch3 y 7 sobre arch4. Cada pregunta tiene una respuesta de referencia extraída del manual, la fuente esperada y las páginas donde está la respuesta.

La métrica de recuperación es el recall fuente+página@5: la fracción de pares (fuente, página) esperados que aparecen entre los 5 primeros fragmentos recuperados. Es más estricta que el Recall@K del Sprint 2, porque la página tiene que venir del PDF correcto.

El script optimizacion/baseline.py corre el pipeline completo pregunta por pregunta y guarda la traza de cada una (contexto recuperado, respuesta y referencias) en un JSONL. Si una pregunta falla, la siguiente corrida la vuelve a ejecutar sin repetir las demás.

3.2 Regresión de Recall por Entidades Inferidas

Las primeras corridas con Qwen dieron un recall de 0.22. El diagnóstico encontró dos causas:

- Qwen agregaba entidades que no estaban en la consulta. En la búsqueda por palabras clave, esas entidades puntuaban 0.95 y desplazaban a los fragmentos relevantes.
- Los fragmentos de arch2 no tenían dominio asignado, porque las reglas de entidades no cubrían cartílago, tejido óseo, tejido muscular ni tejido nervioso.

La corrección tiene dos partes. Una entidad que propone el LLM solo se conserva si aparece en la consulta y no la detectaron ya las reglas. Y se agregaron los cuatro dominios de arch2 a REGLAS_ENTIDADES. En una simulación de la búsqueda por palabras clave, el recall subió de 0.844 a 0.893; en el baseline completo (v1) quedó en 0.872.

3.3 Resultados

El baseline v2, sobre el que se corrió GEPA, obtuvo un recall fuente+página@5 de 0.852:

Fuente	Preguntas	Recall fuente+página@5
arch2.pdf	20	0.825
arch3.pdf	5	0.850
arch4.pdf	7	0.929
Total	32	0.852

La fuente dominante entre los fragmentos recuperados fue la correcta en el 96.9 % de las preguntas. Cada pregunta tardó 14.9 segundos en promedio, con el pipeline completo.

4. Tarea 2: LLM como Juez

4.1 Rúbrica

El juez (optimizacion/juez.py, con gpt-oss-120b) recibe la pregunta, la respuesta de referencia, el contexto recuperado y la respuesta del sistema. Devuelve un JSON con un puntaje entero de 1 a 5 y una justificación para cada dimensión:

Dimensión	Qué mide	Peso
Corrección	Coincide con la respuesta de referencia del manual	0.35
Fidelidad	Todo lo afirmado está sustentado en el contexto recuperado	0.30
Notación	Terminología y notación histológica correctas y precisas	0.20

Dimensión	Qué mide	Peso
Estilo docente	Explica como lo haría un docente de la cátedra	0.15

El puntaje global va de 0 a 1. Cada dimensión se normaliza y se promedia con su peso:

$$\text{global} = \sum \text{peso}_d \cdot (\text{puntaje}_d - 1) / 4 \quad / \quad \sum \text{pesos}$$

Además del juez, el script verifica las citas sin LLM: si la respuesta cita una fuente, si la fuente citada está en el contexto y si es la fuente esperada.

4.2 Ajustes entre el Baseline v1 y el v2

Las justificaciones del juez sobre el baseline v1 mostraron dos problemas, que se corrigieron antes del v2. Ninguno de los dos cambios toca la recuperación:

- Prompt en modo texto: el prompt incluía un bloque de metadatos de búsqueda (TÉRMINOS, ENTIDADES, TEMA y ANÁLISIS VISUAL). Con ese bloque, Qwen respondía "el manual no contiene..." aunque el contexto sí tenía la respuesta. Se sacó del modo texto; el modo multimodal quedó igual (se verificó que el prompt multimodal sea idéntico en 32 combinaciones).
- Golden set: la referencia de la pregunta #22 (conductos de Havers y Volkmann) se reescribió, porque el manual no describe la diferencia entre ambos conductos: solo los nombra como estructuras del hueso compacto (páginas 9 y 16). En la #31 (células endomelicarias) se corrigieron las páginas de referencia a 30, 31 y 35.

4.3 Resultados

El puntaje global subió de 0.729 a 0.788. La mayor mejora fue en fidelidad (+0.41) y corrección (+0.25):

Métrica	Baseline v1	Baseline v2	Δ
Recall fuente+página@5	0.872	0.852	-0.020
Puntaje global del juez (0-1)	0.729	0.788	+0.060
Corrección (1-5)	3.47	3.72	+0.25
Fidelidad (1-5)	4.25	4.66	+0.41
Notación (1-5)	4.59	4.72	+0.13
Estilo docente (1-5)	3.38	3.41	+0.03

Pregunta por pregunta, el v2 es mejor en 14, peor en 7 e igual en 11. Por fuente, el puntaje global del v2 fue 0.771 en arch2, 0.805 en arch3 y 0.827 en arch4. El 100 % de las respuestas cita una fuente, la fuente citada está en el contexto y es la esperada.

La diferencia de recall entre v1 y v2 se explica sobre todo por las páginas de referencia corregidas en #22 y #31, ya que entre ambas corridas no se modificó la recuperación.

5. Tarea 3: Optimización del Prompt con DSPy GEPA

5.1 Configuración

GEPA (`optimizacion/gepa.py`) evoluciona la instrucción de respuesta. En cada iteración evalúa un candidato sobre 3 preguntas de entrenamiento, le pasa las justificaciones del juez a un modelo de reflexión, y este propone una instrucción nueva. Si la nueva mejora esas 3 preguntas, se evalúa sobre todo el conjunto de validación.

Parámetro	Valor
Modelo de respuesta	qwen/qwen3.8-27b, el mismo de producción
Juez y reflexión	openai/gpt-oss-120b
Train / validación	22 / 10 preguntas del golden set (semilla 0)
Contexto	El recuperado en el baseline v2, truncado a 4.000 caracteres como en producción
Presupuesto	100 evaluaciones de la métrica (se usaron 90)
Métrica	Puntaje global del juez, con sus justificaciones como feedback
Duración	10 minutos, con 3 keys de Groq

5.2 Protección de la Cuota

GEPA y `dspy.Evalute` convierten cualquier excepción en un puntaje 0 y siguen. Si la cuota se agota a mitad de la corrida, GEPA seguiría optimizando contra ceros y el prompt resultante no valdría nada. Esto pasó en la primera corrida con `--budget light`: duró 3 horas y agotó la cuota diaria del juez.

Para evitarlo se agregaron cuatro protecciones:

- El primer límite de uso que la rotación no resuelve marca la corrida. Las llamadas siguientes fallan sin ir a la API y el resultado no se guarda.
- DSPy ya no reintenta por su cuenta (`num_retries=0`): sus reintentos dormían el tiempo de espera de Groq, que con la cuota diaria agotada son minutos por llamada. Los 429 los resuelve el rotador.
- Las respuestas que vuelven del caché de DSPy se normalizan (de `AttributeDict` a `dict`), porque GEPA las rechazaba al retomar una corrida. Así, una corrida cortada retoma casi donde quedó.

- La respuesta del generador se limita a 900 tokens (GEPA_MAX_TOKENS_TAREA), por debajo del límite de salida de Qwen, y un pedido rechazado por tamaño corta la corrida con su propio mensaje.

5.3 Resultados

GEPA no encontró un prompt mejor. El mejor programa que devolvió es la semilla misma, con 0.922 en validación, y ninguno de los 6 candidatos la superó:

Programa	Puntaje en validación (0–1)
Semilla (prompt actual)	0.922
Candidato 2	0.918
Candidato 1	0.906
Candidato 6	0.873
Candidato 4	0.854
Candidato 3	0.848
Candidato 5	0.840

Hay tres razones para que no mejore:

- Casi no queda margen: la semilla saca 0.922, y 8 de las 10 preguntas de validación están entre 0.9 y 1.0.
- La pregunta que falla depende de la recuperación. En la #30 (oligodendrocitos), la semilla saca 0.54 y los candidatos entre 0.0 y 0.2. El fragmento recuperado se corta antes de la función de la célula, y ningún prompt puede compensarlo.
- Los prompts más largos empeoran esa pregunta. GEPA agregó reglas sobre cuándo decir que la información no está, y con ellas Qwen responde que el manual no la trae.

Además, con 10 preguntas de validación cada una pesa un 10 % del promedio, así que diferencias de 0.01 entre prompts son ruido. La decisión es mantener el prompt actual: PROMPTS_OPTIMIZADOS queda en false.

6. Limitaciones: Preguntas que Siguen Fallando

Las 6 preguntas con puntaje global menor a 0.6 en el baseline v2 fallan por recuperación, no por el prompt: el fragmento con la respuesta no llega al modelo, o llega cortado.

#	Pregunta	Global v2	Causa probable
27	Clasificación de neuronas por número de prolongaciones	0.00	El fragmento se corta en "Por el número de prolongaciones p...", antes de la lista
31	Células endimarias	0.10	Solo se recupera el epígrafe de la Imagen 15.5, no el párrafo que las define
0	Capas de la arteria muscular	0.35	Se recuperan encabezados de imágenes en vez del texto que describe las tunicas
15	Estructuras de la lámina de laringe 43	0.49	No se recupera el fragmento de la Imagen 11.2 (Laringe 43)
23	Función y ubicación de los osteoclastos	0.54	No se recupera el fragmento de osteoclastos y lagunas de Howship
30	Función de los oligodendrocitos	0.54	El fragmento se corta antes de la función (formación de mielina)

La causa común es el chunking: los fragmentos de 500 caracteres cortan oraciones a la mitad, y las listas y definiciones quedan repartidas entre dos fragmentos.

7. Organización del Repositorio

El trabajo de la etapa está en la rama `feat/dspy-gepa`. Los scripts de evaluación y optimización están en `app/optimizacion/`:

`app/optimizacion/`

```
├─ modelos.py      # lista y prueba los modelos de Groq
├─ baseline.py     # pipeline completo sobre el golden set
├─ juez.py         # LLM como juez con la rúbrica docente
├─ gepa.py         # optimización del prompt con DSPy GEPA
├─ comparar.py     # compara dos corridas pregunta por pregunta
└─ resultados/    # JSONL de cada corrida y logs de GEPA
```

La secuencia de comandos para reproducir la etapa, desde `app/`:

```
uv run python -m optimizacion.modelos --probar
uv run python -m optimizacion.baseline --salida
optimizacion/resultados/baseline-v2.jsonl
uv run python -m optimizacion.juez optimizacion/resultados/baseline-v2.jsonl
uv run python -m optimizacion.comparar <corrida-A>-juez.jsonl <corrida-B>-juez.jsonl
uv run python -m optimizacion.gepa optimizacion/resultados/baseline-v2.jsonl
--max-metric-calls 100
```

8. Conclusiones y Próximos Pasos

La Etapa 2 dejó una evaluación reproducible de punta a punta: el baseline mide la recuperación, el juez mide las respuestas y GEPA prueba variantes del prompt con la misma métrica. Con esa evaluación se corrigió el prompt y el golden set, y el puntaje del juez subió de 0.729 a 0.788. GEPA confirmó que el prompt actual es el mejor que encontró, así que el margen que queda está en la recuperación.

Estado de las tareas de la etapa:

Tarea	Estado	Notas
Migración de modelos	Completada	qwen3.8-27b y gpt-oss-120b
Baseline reproducible	Completada	Recall fuente+página@5 = 0.852 sobre 32 preguntas
LLM como juez	Completada	Puntaje global 0.729 → 0.788
Optimización con GEPA	Completada, sin mejora	Semilla 0.922 = mejor programa; no se activa
Chunking y recuperación	Pendiente	6 preguntas con puntaje menor a 0.6

Próximos pasos:

- Rehacer el chunking para que respete oraciones, listas y definiciones, y reindexar los tres manuales.
- Volver a correr el baseline y el juez sobre las mismas 32 preguntas y compararlos contra el v2 con `comparar.py`.
- Si la cátedra provee respuestas de referencia propias, volver a correr GEPA con `--ejemplos-docente`. El estilo docente es la dimensión más baja (3.41 sobre 5) y es la que un prompt puede mejorar.